

깊이 감독 Dynamic NeRF: 제한된 카메라를 이용한 동적 장면 재구성

김규민⁰, 박동하⁰, 이채은¹
인하대학교 정보통신공학과⁰, 한양대학교 융합전자공학부¹
{kkm8121, donghaha12}@naver.com, chree@hanyang.ac.kr

Depth Supervised Dynamic NeRF: Dynamic Scene Reconstruction with Limited Cameras

Kyu Min Kim⁰, Dong Ha Park⁰, Chae Eun Rhee¹
Inha University Information and Communication Engineering⁰, Hanyang University Electronic Engineering¹

요약

본 논문은 고품질 3D 장면을 합성하는 Neural radiance fields (NeRF)[1] 기반 연구 중 다중 시점 비디오 입력으로 동적 장면을 효율적으로 학습하는 MixVoxels[2]에서 학습에 너무 많은 카메라가 사용되는 문제를 해결하는 방법을 제시한다. 본 논문에서는 먼저 한 대의 카메라를 통해 얻은 데이터를 이용하여 정적 모델을 학습한다. 그리고 정적 모델에서 얻은 깊이 정보를 증류하여 Fine 모델을 학습한다. 최종적으로 얻은 모델은 학습에 적은 수의 카메라를 사용했음에도 정적인 영역과 동적인 영역이 높은 품질로 학습된 모델이다.

1. 서론

다중 시점 비디오 입력으로 동적 장면을 재구성하는 것은 큰 주목을 받는 주제이다. 이는 virtual reality/augmented reality (VR/AR), 게임 및 영화 산업, 3-dimensional (3D) 콘텐츠 등 많은 응용 분야에 사용된다. MixVoxels[2]는 다중 시점 비디오 합성에 심층 신경망을 이용하여 새로운 시점의 장면을 높은 성능으로 합성하는 NeRF[1]를 접목하여 동적 장면을 매우 사실적으로 재구성하고 있다. MixVoxels[2]은 높은 품질로 새로운 시점의 장면을 재구성하지만 학습에 매우 많은 카메라가 사용되고 그로 인해 많은 이미지가 학습에 입력으로 주어진다 단점이 있다. 또한 학습에 사용되는 카메라의 개수를 줄였을 경우에 매우 큰 성능 하락이 발생한다. 본 연구는 학습에 사용되는 카메라의 개수를 줄이더라도 동등하거나 높은 품질의 장면 재구성을 달성하는 것을 목표로 한다. 이를 위해서 깊이 정보를 얻을 수 있는 정적 모델 학습과, 깊이 정보를 이용하여 적은 숫자의 카메라로도 사실적인 동적 장면을 재구성

하는 Fine 모델 학습으로 나누어 학습 파이프라인을 구성한다. 또한 정적 모델로 얻은 깊이 정보를 이용하여 3차원에 존재하는 실제 물체의 위치를 파악하고 이 위치의 주변에 더 많은 샘플링을 진행하는 깊이 감독 샘플링을 제안한다.

2. 깊이 감독 Dynamic NeRF

그림 1은 본 논문의 학습 파이프라인을 의미한다. 우선 정적인 영역의 깊이 정보를 추출할 수 있는 정적 모델을 학습한다. 정적 모델로부터 장면의 정적인 영역의 깊이 정보를 추출할 수 있다. 그리고 정적 모델로부터 얻은 깊이 맵(depth map)을 추가의 입력으로 사용하여 Fine model을 학습한다. NeRF[1]에서는 ground truth(GT) RGB와 모델이 추론한 RGB 사이의 평균제곱 오차를 계산하여 손실 함수를 정의한다. 본 논문에서는 NeRF의 RGB 손실 함수에 깊이 손실 항을 추가한다. 깊이 손실 항은 Fine 모델이 추론한 장면의 깊이 맵과 정적 모델로 얻은 깊이 맵 사이의 평균제곱오차를 계산하여 얻은 값이다.




그림 1. 깊이 감독 Dynamic NeRF 전체 파이프라인

2.1. 정적 모델 학습

한 대의 카메라를 통해 3차원 장면의 정적인 영역을 학습하여 깊이 정보를 추출한다. 학습하는 장면이 정적이라고 가정한다면, 카메라 한 대를 사용하여 시점을 변화시켜가며 정적인 영역을 학습할 수 있다. 3D 장면의 대부분은 정적인 영역이기 때문에 정적 모델을 통해 얻은 깊이 정보는 신뢰할 수 있는 정보이다.

* ¹교신저자

* 포스터 발표논문, 학부생 주저자 논문

* 본 연구는 과학기술정보통신부 및 정보통신기획평가원의 대학 ICT연구센터육성지원사업의 연구결과로 수행되었음. (IITP-2022-RS-2022-00156225)

2.3. 깊이 감독 샘플링

그림 2은 MixVoxels[2]와 본 논문의 샘플링 방식 차이를 설명한다. MixVoxels[2]은 그림2(a)에서처럼 광선을 따라 3차원의 점의 위치를 균일하게 샘플링한다. 따라서 카메라 사용이 적은 상황에서 학습에 사용되는 정보가 부족한 위치와 충분한 위치의 차이를 고려하지 못한다. 이러한 차이 때문에 재구성된 장면에서 두 부분의 합성 품질은 큰 차이가 발생하게 된다. 이를 해결하기 위해 본 논문에서는 그림2(b)의 깊이 감독 샘플링을 제안한다. 정적 모델에서 얻은 깊이 정보를 이용하여 3차원 상의 물체의 위치를 추정할 수 있고 이 위치가 샘플링 확률 분포의 평균 지점이 되도록 가우시안(Gaussian) 샘플링 한다. 이를 통해 학습에 사용되는 정보가 부족한 부분은 상대적으로 많이 샘플링하고 정보가 충분한 부분은 적게 샘플링 한다. 이는 재구성된 장면이 균일한 합성 품질을 달성할 수 있게 한다.




그림 2. 깊이 감독 샘플링

3. 실험 결과

표 1은 MixVoxels[2]에서 학습에 사용되는 카메라 수에 따른 재구성 품질 차이를 나타낸 표이다. 카메라 수가 감소함에 따라 학습에 사용되는 이미지의 수가 감소하고 이로 인해 재구성되는 장면에서 큰 성능 감소가 발생했다. 표 2는 본 논문 성능 검증을 위하여 카메라 2대를 사용하여 진행한 학습을 기준으로 본 논문과 MixVoxels[2]의 재구성 품질 차이를 나타낸 표이다. 본 논문의 방법을 사용하면 동일한 카메라 개수와 3.3%의 이미지 입력 추가로 정적인 영역 PSNR 6.19db, 평균 PSNR 4.05db의 성능 향상을 달성했다. 그림 3은 표 1, 표2의 학습 결과이다. 그림3(a)는 실제 카메라로 취득한 이미지, 그림3(b)는 MixVoxels[2]에서 카메라 20대로 학습한 결과, 그림3(c)는 MixVoxels[2]에서 카메라 2대로 학습한 결과, 그림3(d)는 본 논문의 방법으로 카메라 2대로 학습한 결과이다. 그림3(b)와 그림3(c)를 비교하면 학습에 사용된 카메라의 개수가 줄어들어 따라 큰 성능 하락이 발생했다. 그림3(c)와 그림3(d)를 비교하면 카메라 개수의 부족으로 성능 하락이 발생한 상황에서, 본 논문의 방법을 통해 학습에 사용되는 정보의 부족을 깊이 정보로 보완하여 재구성 품질을 향상시켰다.

카메라 수	이미지 수	PSNR(dB)	PSNR_STA(dB)
20	6000	32.55	32.76
5	1500	23.73	24.45
2	600	20.96	21.76

표 1. MixVoxels 학습에 사용되는 카메라 수에 따른 성능 차이, PSNR_STA는 정적인 영역의 PSNR

모델	이미지 수	PSNR(dB)	PSNR_STA(dB)
MixVoxels	600	20.96	21.76
Ours	620	25.01	27.95

표 2. 카메라 두 대를 사용한 학습을 기준으로 성능 비교




그림 3. MixVoxels과 본 논문으로 학습한 모델에서 새로운 시점의 장면 추론 결과

4. 결론

본 논문은 깊이 감독을 사용하여 동적 장면을 효율적으로 학습하는 방법을 제안하며, 정적 모델과 Fine 모델을 분리하여 학습하는 방식을 통해 적은 수의 카메라로도 높은 품질의 동적 장면 재구성을 가능하게 한다. 본 논문의 방법으로 학습된 모델은 정적인 영역에서 상당한 성능 향상을 달성했지만 동적인 영역은 정적인 영역에 비해 상대적으로 적은 성능 향상을 달성했다. 향후 연구에서는 정적인 영역과 동적인 영역이 균일한 품질로 학습을 진행하는 방법을 연구해보고자 한다.

참고문헌

- [1] Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik, Jonathan T. Barron, Ravi Ramamoorthi, and Ren Ng, "Nerf: Representing scenes as neural radiance fields for view synthesis," In European Conference on Computer Vision (ECCV), pp. 405-421, 2020.
- [2] Feng Wang, Sinan Tan, Xinghang Li, Zeyue Tian, Yafei Song, and Huaping Lui, "Mixed Neural Voxels for Fast Multi-view Video Synthesis," In IEEE International Conference on Computer Vision (ICCV), pp. 19706-19716, 2023.
- [3] Kangle Deng, Andrew Liu, Jun-Yan Zhu, and Deva Ramana, "Depth-supervised NeRF: Fewer Views and Faster Training for Free," In IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 12882-12891, 2022.